Nr.	Autor(i) / An	Titlul articolului / proiectului	Aplicație / Domeniu	Tehnologii utilizate	Metodologie / Abordare	Rezultate	Limitări	Comentarii suplimentare
1	Keiley Mead, Tom Cross, Greg Roger, Rohan Sabharwal, Sahaj Singh, d Nicola Giannott, 2025	MRI deep learning models for assisted diagnosis of knee pathologies: a systematic review	Diagnosticarea anomaliilor genunchiului cu ajutorul imaginilor RMN	Modele Deep Learning, rețele CNN (ResNet, VGG, DenseNet, DarkNet), seturi de date RMN (2D și 3D, ex: MRNet)	Analiza performanțelor algoritmilor DL pe diverse afecțiuni (ACL, menisc), analizând impactul tehnicilor de data augmentation și transfer learning.	Modelele specifice pe o singură patologie sunt mai precise decât cele de detecție generală.	Lipsa standardizării datelor, absența unui diagnostic de referință clar	Articolul sugerează să ne axăm pe o singură afecțiune pentru a obține o acuratețe mai bună și să definim extrem de clar metricele și ground-truth-ul.
2	Kowshik Deb Nath, A. F. M. Minhazur Rahman, Md. Ali Hossain, 2023	An Attention-Based Deep Learning Approach to Knee Injury Classification from MRI Images	Diagnosticarea anomaliilor genunchiului cu ajutorul imaginilor RMN	Rețele Neuronale Convoluționale, Mecanism de Atenție, Data Augmentation	S-a extins CNN-ul de bază prin adăugarea unor module de atenție după primele straturi de convoluție ca modelul să extragă selectiv informațiile relevante și să elimine zgomotul. S-a folosit data augmentation pentru combaterea overfitting-ului.	Adăugarea modulului de atenție ajutat la obținerea acurateții de 100% pentru clasificarea binară și de 91% pentru multi-clasă. S-au calculat și metrice de Precizie, Recall și F1-Score.	Setul de date multi-clasă este dezechilibrat, iar modelul cu atenție este mult mai complex computațional, având milioane de parametri antrenabili	Am învățat că integrarea unui bloc Squeeze-and-Excitation peste un CNN clasic crește capacitatea algoritmului de a distinge leziunile subtile.
3	Priya Mittal, Bhisham Sharma, D.P. Yadav, Imed Ben Dhaou, 2025	Automated Knee Injury Detection in MRI Images Using Vision Transformers	Diagnosticarea anomaliilor genunchiului cu ajutorul imaginilor RMN	Vision Transformers(ViT), Transfer Learning, Binary Cross-Entropy Loss, Data Augmentation.	Înlocuirea totală a rețelelor CNN cu modele ViT care folosesc mecanisme de self-attention. Imaginile RMN sunt împărțite în fragmente, și se adăugă informații de poziție.	Modelul ViT a depășit rețeaua CNN de bază obținând: acuratețe de 96.5%, precizie de 95.8%, recall de 94.6% și F1-score de 95.2%.	Modelele Transformer necesită putere de calcul mare față de modelele CNN clasice.	Un algoritm de tip Vision Transformer va capta contextul global mult mai bine decât un CNN standard.
4	Kyung Min Chung, 2023	Deep Learning-Based Knee MRI Classification for Common Peroneal Nerve Palsy with Foot Drop	Diagnosticarea anomaliilor genunchiului cu ajutorul imaginilor RMN	EfficientNet-B5, ResNet152, VGG19, Transfer Learning, Hărți termice Grad-CAM.	Comparerea a 3 arhitecturi CNN diferite. Decuparea spațiilor negre, limitarea zonei analizate, redimensionare 224x224, normalizare Z-score, fără data augmentation.	EfficientNet-B5 a fost superior: AUC 0.946, acuratețe 88.1%, F1-Score 84.6%. Hărțile Grad-CAM au demonstrat concentrarea precisă a modelului pe zona nervului lezat.	Lipsa datelor despre momentul producerii leziunii (care afectează aspectul RMN-ului); decuparea prea strictă a imaginilor a ignorat anumiți mușchi utili; număr mic de pacienți.	Demonstrează că un model echilibrat (EfficientNet) e mai bun decât unul doar adânc.
5	Justin Bernard A. Carlos, 2021	MRI Knee Image Enhancement using Image Processing	Diagnosticarea anomaliilor genunchiului cu ajutorul imaginilor RMN	Python, Algoritmul Canny Edge, Transformări morfologice (Eroziune), Filtre (Gaussian).	Conversia datelor din format brut k-space în imagini. Aplicarea unui pipeline clasic de preprocesare (mască de ROI, detectarea marginilor, eroziune) pentru atenuarea artefactelor.	Reducerea vizuală a zgomotului de fond și a artefactelor de mișcare din RMN, îmbunătățind claritatea trăsăturilor.	Nu elimină complet artefactele. Set de date infim. Definirea manuală a ROI-ului (hardcoded), nu automată.	Ajută la realizarea etapei de preprocesare (Image Enhancement) din schema bloc a proiectului.